

FAQ del Producto

Tecnologías utilizadas

Se utiliza una arquitectura cloud en AWS y una aplicación web en Streamlit. El almacenamiento es en Amazon S3 (con arquitectura medallion: capas bronze, silver y gold). De igual forma se usa AWS Glue para registrar las tablas generadas en S3. Athena igual se usa para hacer las consultas mediante SQL. Se utilizan scripts de Python donde se realizan en entrenamiento y generación de predicciones. La aplicación final esta construida con Streamlit y se despliega como contenedor Docker. La imagen Docker se publica en Amazon ECR y se ejecuta en ECS Fargate. La comunicación con Athena desde la aplicación se plantea mediante SQLAlchemy.

Cómo se utiliza la solución

El usuario final entra a la URL pública de la aplicación web sin necesidad de descargar datos ni ejecutar código. Desde la interfaz puede revisar un resumen ejecutivo del estado de los clientes, analizar el riesgo promedio por tipo de contrato, consultar rankings de clientes con mayor probabilidad de churn y revisar el perfil individual de un cliente. También puede hacer otros filtros e inclusive se puede descargar el ranking filtrado.

Cómo se adquieren y usan los datos.

Los datos se adquirieron del dataset Telco Customer Churn de Kaggle, el cual tiene información histórica de clientes de una empresa de telecomunicaciones, incluyendo variables demográficas, servicios contratados, tipo de contrato, entre muchas otras, incluida la variable objetivo Churn. Los datos se guardan y transforman en Amazon S3. En esta etapa se corrigen tipos de variables, se transforma TotalCharges a numérico, se codifica la variable objetivo y se normalizan nombres de columnas. Posteriormente, el proceso de entrenamiento utiliza la capa

silver para entrenar modelos de clasificación. También se genera la capa gold con las probabilidades de churn, niveles de riesgo, predicciones y métricas del modelo. Las tablas de silver y gold se registran en Glue Data Catalog y se consultan con Athena. La aplicación Streamlit consume la capa gold por medio de consultas SQL, usando SQLAlchemy como interfaz de conexión.

Qué tipo de analítica o inteligencia se aplica (modelos estadísticos, ML, LLMs, agentes, etc.).

La solución aplica machine learning supervisado para clasificación binaria. Se entrenaron modelos como regresión logística y random forest, y se comparan mediante métricas de evaluación. El modelo seleccionado fue regresión logística, ya que obtuvo el mejor desempeño. El modelo genera una probabilidad de churn para cada cliente. Posteriormente, esa probabilidad se convierte en niveles de riesgo.

Inputs y outputs del producto

Cada registro representa un cliente e incluye variables como: customer_id, gender, seniorcitizen, partner, dependents, tenure, phoneservice, multiplelines, internetservice, onlinesecurity, onlinebackup, deviceprotection, techsupport, streamingtv, streamingmovies, contract, paperlessbilling, paymentmethod, monthlycharges, totalcharges y churn.

Los principales outputs son : probabilidad de churn por cliente, nivel de riesgo: bajo, medio o alto, ranking de clientes ordenados por riesgo, métricas del modelo, resúmenes agregados por tipo de contrato y tablas descargables para campañas de retención.

Cómo consume el usuario final los outputs.

El usuario los consume mediante una aplicación web desplegada en AWS. La aplicación no requiere que el usuario final conozca S3, Athena o Python ni nada por el estilo, ya que es muy interactiva. El usuario solo necesita

entrar al link público y mover lo que crea necesario para su toma de decisiones.

Cuánto costaría la solución a un año

En una implementación productiva, el costo anual incluiría almacenamiento en S3, consultas en Athena, Glue Data Catalog, ECR, cómputo en ECS Fargate. Depende mucho del volumen . El costo anual estimado sería de aproximadamente 380 a 420 USD, equivalente a cerca de 6,500 a 7,100 MXN usando un tipo de cambio de referencia de 17 pesos por dólar. Si la aplicación se apaga cuando no está en uso, el costo bajaría considerablemente y podría quedar en menos de 50 USD al año.

Limitaciones

El dataset es histórico y no está conectado todavía a una fuente transaccional en tiempo real. Otra limitación es que el modelo se entrena sobre un dataset público y no sobre datos internos de una empresa real.