

FAQ del Producto

Tecnologías utilizadas

Se utiliza una arquitectura cloud en AWS y una aplicación web en Streamlit. El almacenamiento es en Amazon S3 mediante una arquitectura medallion con capas bronze, silver y gold. También se utiliza AWS Glue Data Catalog para registrar las tablas generadas en S3 y Amazon Athena para consultar los datos mediante SQL. El procesamiento de datos, entrenamiento del modelo y generación de predicciones se realiza con scripts de Python. La aplicación final está construida con Streamlit y se despliega como contenedor Docker. La imagen Docker se publica en Amazon ECR y se ejecuta en Amazon ECS Fargate. El acceso público a la aplicación se realiza mediante un Application Load Balancer.

Cómo se utiliza la solución

El usuario final entra a la URL pública de la aplicación web sin necesidad de descargar datos ni ejecutar código. Desde la interfaz puede revisar un resumen ejecutivo del estado de los clientes, analizar el riesgo promedio por tipo de contrato, consultar rankings de clientes con mayor probabilidad de churn y revisar el perfil individual de un cliente. También puede hacer otros filtros y descargar el ranking filtrado.

Cómo se adquieren y usan los datos.

Los datos se adquieren del dataset Telco Customer Churn de Kaggle. Este dataset contiene información histórica de clientes de una empresa de telecomunicaciones, incluyendo variables demográficas, servicios contratados, tipo de contrato, cargos mensuales, cargos totales, método de pago y la variable objetivo Churn. El proceso inicia con la descarga directa desde kaggle y la subida del archivo a Amazon S3. Después, el script de transformación genera la capa Silver, donde se corrigen tipos de variables, se transforma TotalCharges a numérico, se codifica la variable objetivo y se normalizan los nombres de columnas.

Posteriormente, el proceso de entrenamiento utiliza la capa Silver para entrenar modelos de clasificación. Finalmente, se genera la capa Gold, que contiene las probabilidades de churn, niveles de riesgo, predicciones, métricas del modelo y el artefacto del modelo entrenado.

Las tablas de Silver y Gold se registran en AWS Glue Data Catalog y pueden consultarse con Amazon Athena. La aplicación Streamlit consume directamente los archivos principales de la capa Gold desde S3: churn_predictions.parquet y model_metrics.csv.

Modelos estadísticos

La solución aplica machine learning supervisado para clasificación binaria. Se entrenaron modelos dos modelos: regresión logística y random forest, y se comparan mediante métricas de evaluación. El modelo seleccionado fue regresión logística, ya que obtuvo el mejor

desempeño. El modelo genera una probabilidad de churn para cada cliente. Posteriormente, esa probabilidad se convierte en niveles de riesgo.

Inputs y outputs del producto

Cada registro representa un cliente e incluye variables como: customer_id, gender, seniorcitizen, partner, dependents, tenure, phoneservice, multiplelines, internetservice, onlinesecurity, onlinebackup, deviceprotection, techsupport, streamingtv, streamingmovies, contract, paperlessbilling, paymentmethod, monthlycharges, totalcharges y churn.

Los principales outputs son: probabilidad de churn por cliente, nivel de riesgo: bajo, medio o alto, ranking de clientes ordenados por riesgo, métricas del modelo, resúmenes agregados por tipo de contrato y tablas descargables para campañas de retención.

Cómo consume el usuario final los outputs.

El usuario los consume mediante una aplicación web desplegada en AWS. La aplicación no requiere que el usuario final conozca S3, Athena o Python ni nada por el estilo, ya que es muy interactiva. El usuario solo necesita entrar al link público y mover lo que crea necesario para su toma de decisiones.

Cuánto costaría la solución a un año

En una implementación productiva, el costo anual incluiría principalmente almacenamiento en S3, consultas en Athena, Glue Data Catalog, almacenamiento de imagen en ECR, cómputo en ECS Fargate, Application Load Balancer y logs en CloudWatch.

Para una prueba de concepto con pocos datos y uso limitado, el costo esperado es bajo. Si la aplicación se mantiene encendida continuamente, el costo anual podría estar aproximadamente entre **380 y 420 USD**, equivalente a cerca de **6,500 a 7,100 MXN** usando un tipo de cambio de referencia de 17 pesos por dólar.

Si la aplicación se apaga cuando no está en uso o se optimizan los recursos activos, el costo bajaría considerablemente y podría quedar por debajo de **50 USD al año** para una prueba de concepto de baja frecuencia de uso.

Limitaciones

El dataset es histórico y no está conectado todavía a una fuente transaccional en tiempo real. Otra limitación es que el modelo se entrena sobre un dataset público y no sobre datos internos de una empresa real.