

Customer Churn Risk Dashboard

Emiliano Islas Flores
Raúl Mora Hernandez






Problema

Una empresa de telecomunicaciones puede perder clientes, pero no siempre sabe **cuáles clientes están más cerca de cancelar**.

Si el área de retención contacta clientes al azar, puede gastar tiempo y recursos en personas que realmente no iban a abandonar el servicio, mientras deja pasar clientes con riesgo alto.




Oportunidad

La oportunidad del producto es usar datos históricos para estimar la **probabilidad de churn** de cada cliente.

El dashboard permite anticipar el riesgo y priorizar acciones de retención



A close-up photograph of a person's hand holding a pen, pointing at a document. The background is blurred, showing what appears to be a desk or office environment. The text 'Usuario Final' is overlaid on the left side of the image.

Usuario Final

El usuario final es el **equipo de retención, customer success o marketing** de una empresa de telecomunicaciones.

Este usuario no necesariamente es técnico, por eso el producto se entrega como una aplicación web donde puede consultar resultados sin correr código ni hacer consultas SQL manualmente.



Beneficio

En vez de revisar toda la base completa, la app le muestra qué clientes tienen mayor probabilidad de abandonar, cuál es su nivel de riesgo y qué características están asociadas a ese riesgo, como contrato mes a mes, poca antigüedad o cargos mensuales altos.

Jan

Feb

Mar

Apr

May

Jun

Jul

Aug

Sept

Oct

Nov

Dec





Datos utilizados


Usamos el dataset
**Telco Customer
Churn**, publicado en
Kaggle

Contiene **7,043**
clientes y variables
sobre datos
demográficos, servicios
contratados,
información de cuenta y
la variable objetivo
Churn

El archivo no trae una columna de fecha
transaccional como **month** o **date**. Por eso
el proyecto no se trata como serie de tiempo.
Es un corte histórico de clientes, donde
tenure representa la antigüedad del cliente
en meses y **Churn** indica si abandonó en el
último mes



Customer Churn Data Product Architecture





Entrenamiento

El problema se formuló como clasificación binaria:

Churn = 1 si el cliente abandonó

Churn = 0 si el cliente no abandonó

Se probaron dos modelos:

1. Regresión logística
2. Random Forest

El modelo seleccionado fue: Logistic regression porque tuvo el mejor ROC AUC.

Modelo: logistic_regression
Accuracy: 0.750
Precision: 0.519
Recall: 0.797
F1: 0.628
ROC AUC: 0.846

Modelo: random_forest
Accuracy: 0.775
Precision: 0.558
Recall: 0.730
F1: 0.633
ROC AUC: 0.843



Aunque Random Forest tuvo un poco más de accuracy y F1, la regresión logística tuvo mejor ROC AUC y mejor recall. En un problema de churn, el recall es importante porque nos interesa detectar la mayor cantidad posible de clientes que podrían abandonar.

A partir de la probabilidad estimada por el modelo, se creó una variable `risk_level`:

Bajo: `prob_churn < 0.40`

Medio: `0.40 <= prob_churn < 0.70`

Alto: `prob_churn >= 0.70`

<code>risk_level</code>	<code>clientes</code>	<code>prob_churn_promedio</code>	<code>churn_real_promedio</code>
Alto	1766	0.813	0.628
Medio	1695	0.553	0.306
Bajo	3582	0.152	0.068

Resultados Principales

El resultado más claro es que el tipo de contrato está muy asociado al riesgo promedio de churn.

Month-to-month: riesgo promedio 0.629

One year: riesgo promedio 0.238

Two year: riesgo promedio 0.077

Esto tiene sentido de negocio: los clientes con contrato mes a mes tienen menos fricción para irse, mientras que los clientes con contratos de uno o dos años tienden a permanecer más tiempo.

<http://churn-streamlit-alb-1369386964.us-east-1.elb.amazonaws.com/>